Documentação de testes e validação da CAPITU

Sincronização obrigatória: o Markdown é a fonte textual; qualquer alteração deve ser refletida no DOCX e no PDF do mesmo nome-base antes do commit.

PDF correspondente: `CAPITU_Documentacao_Padrao_e_Plano_de_Testes.pdf`

Documentação de testes e validação

Chatbot inteligente de descoberta bibliográfica • A3 de Inteligência Artificial • 7 de outubro de 2026

Equipe: Emely, Millena e Miguel • Entrega: 25/11/2026 • Estado: plano anterior à execução dos testes.

Objetivo deste documento. Definir o que a CAPITU precisa testar, o padrão usado para escrever e registrar casos, os níveis de teste, os critérios de aceite e a relação com as funcionalidades aprovadas. Os cenários esperados são especificações; nenhum resultado é alegado como já observado.

Base consultada: enunciado oficial A3, aula “Tecnologias possíveis e conceitos essenciais”, planejamento detalhado CAPITU e plano de tarefas da equipe. A proposta foi aprovada pelo professor segundo a informação da equipe. Datas/atribuições abaixo seguem o cronograma até 25/11.

Leitura rápida: o que a equipe precisa entregar

Obrigatório para a A3	Planejado para CAPITU	Como evidenciar
20 ou mais perguntas de teste	24 testes de aceitação T01-T24 com esperado, obtido e passou?	Tabela executada com versão, modo e estado inicial
Reformulações, ambiguidades e fora do escopo	Casos diretos, paráfrases, entidade ausente, typo, fallback e mudança de contexto	Suite congelada e regressões
Métricas compatíveis e análise de 3 falhas	Taxa de sucesso, classificação, matriz, fallback; fichas de falhas reais	Cálculos reproduzíveis e causas
Fluxo de entrada a resposta; abstenção	Unitário, diálogo, API controlada, UI, integração ponta a ponta	Automação pytest + tabela/roteiros manuais
Código/dados executáveis e autoria	Sem acesso à rede na suite padrão; instalação limpa; responsabilidades identificáveis	CI/local README e histórico de contribuição

Escopo funcional coberto: buscar por título, buscar obras por autor, buscar por assunto/gênero, consultar detalhes; extração de título/autor/assunto; pergunta de esclarecimento; seleção de resultado; contexto mínimo; rejeição fora do escopo; Open Library pública; falha, retorno vazio, múltiplos resultados, campos ausentes e chat web local. Cache/mode técnico e capas/ISBN como busca são incrementos opcionais e não bloqueiam o MVP.

1. Padrão geral dos testes

Use uma especificação comum para que os três integrantes possam preparar, executar e revisar testes sem alterar o critério depois de observar o resultado.

Campo de cada caso	O que registrar
ID e versão	ID estável; release/commit, configuração do interpretador e versão do dataset
Objetivo/camada	Qual componente e requisito a verificação cobre
Pré-condições	Sessão limpa ou estado prévio, fixtures, cache e dependências
Entrada/ação	Mensagem ou sequência exata; chamada interna ou ação de UI
Esperado/oráculo	Rótulo, entidade, decisão, chamada permitida e resultado visível, definidos antes
Obtido	Saída real, IDs/resposta e scores se diagnóstico ajudar; não reconstruir de memória
Resultado	Passou/falhou/bloqueado/não executado, com motivo e data
Modo	Unitário/mock, integrado controlado, manual ou smoke com API real
Evidência	Log, arquivo, screenshot ou referência ao output sem segredo

Padrão de escrita: Arrange, Act, Assert

Arrange: preparar sessão, corpus e fake da API. Act: chamar um componente ou enviar mensagem. Assert: verificar saída e também efeitos colaterais: score/decisão, entidade, estado de sessão e número de consultas. Um teste que verifica apenas que “não lançou exceção” é insuficiente para o comportamento esperado.

Padrões técnicos adotados

- Teste determinístico: mesma entrada, fixture e versão produzem o mesmo resultado.

- Test doubles: fixture para retorno, mock/fake/spy para HTTP, relógio, cache e contagem de chamadas.
- Sem rede por padrão: unitários e testes de integração usam HTTP simulado; não depender de catálogo vivo.
- Contrato explícito: schemas de request/response, estado de ausência e erro diferentes, campos opcionais.
- Teste de comportamento: assert na decisão observável do usuário, além dos detalhes internos essenciais.
- Independência: teste começa com sessão/cache isolados, não depende da ordem de execução.
- Um motivo principal por caso: vários asserts coerentes são permitidos, mas falha deve apontar camada provável.
- Dados controlados: IDs e campos conhecidos; fixtures são marcadas como simulação, não resultado ao vivo.
- Limite compartilhado: rate limiter testa relógio falso, nunca faz loop de requisições reais para medir quota.
- Regressão: cada erro real escolhido para correção ganha caso repetível; versionar o que entrou no treino depois.

Resultado do caso

Passou: o comportamento observado cumpre todo o oráculo. Falhou: comportamento diverge. Bloqueado: componente/dependência impede execução e há motivo. Não executado: sem tentativa. “Fallback correto” pode passar em entrada desconhecida; uma pergunta ambígua não deve receber rótulo único artificial.

2. O contexto geral e os padrões que os testes devem cobrir

Área	Padrões do produto CAPITU	Pergunta de teste
Intenções	buscar_por_titulo; buscar_obras_autor; buscar_por_assunto; consultar_detalhes	A ação pretendida foi reconhecida?
Entidades	Título, autor, assunto/gênero, identificador e campo solicitado	Parâmetro foi extraído completo e da entidade correta?
Semelhança lexical	TF-IDF/cosseno sobre frases de referência; scores não são probabilidade	Reconhece variante suportada sem exagerar a confiança?
Regra de decisão	Limiar + margem; aceita, esclarece ou abstém	Casos nos limites não disparam consulta errada?
Diálogo	Pendência, seleção numerada, item selecionado, cancelamento e nova demanda	Contexto curto permanece coerente e isolado por sessão?
Dados	Frases autorais/curadas, grupos de variação e splits	Teste está independente; não há vazamento de paráfrase?
Fonte externa	Open Library; obra/edição; campos incompletos	Consulta corresponde ao pedido; erros e limites são seguros?
Resposta	Templates só com dados disponíveis; origem visível	Resposta evita alegar acervo, completude ou dado ausente?
Interface	Chat web desenvolvido por Millena a partir do design; execução local com backend controlado/real	Envio, espera, resultados, seleção, sessão e falhas são visíveis/utilizáveis?
Entrega/defesa	README, código, dados, resultados e contribuição individual	Outra pessoa executa? Cada integrante explica sua parte?

Quatro resultados de intenção não são quatro respostas iguais

“Quais livros Machado escreveu?” → buscar_obras_autor, entity author, lista. “Quem escreveu Dom Casmurro?” → consultar_detalhes, entity title, campo autor. O texto “escreveu” não decide sozinho. Testar o par junto para flagrar regras superficiais.

Cobertura obrigatória da suite funcional

- Pergunta direta e paráfrase natural.
- Sinônimos/estrutura lexical variante e pequeno erro de grafia, com expectativa de sucesso ou esclarecimento definida.
- Ambiguidade e ausência de parâmetros.
- Fora do domínio e operação institucional fora do escopo.
- Livro/autor sem resultado na fonte simulada.
- API indisponível, timeout, limite HTTP, retorno múltiplo e campo ausente.
- Seleção de resultado e continuação curta; nova busca muda o contexto.
- Resultado de cada intenção e uma pergunta inédita na defesa.

Regra de honestidade: um teste de exemplo conhecido mede reprodução da referência. Generalização é medida pelo split independente, por paráfrases agrupadas corretamente e por reformulações inéditas; nenhum conjunto pequeno comprova cobertura geral da língua.

3. Camadas de teste e fronteiras

Nível	Componente/foco	Rede	Executar quando	Dono primário
Unitário - PLN	Normalização, TF-IDF, similaridade, limiar, margem e extração	Não	Em cada mudança na lógica; rápido	Emely
Unitário - diálogo	Estados, pendência, seleção, cancelamento, sessão	Não	Em cada mudança de contexto	Emely
Unitário - serviço	Mapeamento de parâmetros, parse, normalização, HTTP errors, cache/limite se houver	Não	Em cada mudança do adapter	Emely
Integração backend	POST /chat e composição de módulos com cliente fake	Não	Após contrato e integração	Emely; fixture de Miguel
Aceitação T01-T24	Comportamento do sistema como um todo	Controlada por padrão	Marco de avaliação e regressão final	Miguel consolida; todos revisam
UI manual/componente	UI implementada em M02 a partir do design M00; mensagens, loading, seleção, erro e acessibilidade básica	Backend local/mock e integrado	M02, M03, M05 e versão final	Millena
Smoke live opcional	Conexão mínima e esquema da Open Library	Sim, poucas consultas deliberadas	Após adapter ou antes da demo	Miguel sondagem; Emely implementação
Instalação/reprodução	README, env, dados, comandos, execução limpa	Pode começar offline	Antes do pacote e release	Miguel executa; Emely corrige
Defesa/documentação	Pergunta inédita, falha explicada e contribuição	Demonstração controlada ou live identificada	Ensaio e apresentação	Todos

Oráculos e fronteiras de responsabilidade

Especificar oráculos localmente: interpretador retorna intenção, score, margem e decisão; extrator retorna entidade tipada; diálogo retorna pergunta/seleção/consulta; adapter converte resposta externa em modelo interno; UI mostra estado. Se o comportamento falhar, essa separação ajuda a localizar causa sem atribuir automaticamente todo erro à IA.

Mocks: use resposta controlada para vazio, múltiplos resultados e campos ausentes. Live: uma chamada real pode comprovar conectividade naquela hora, mas não é estável nem mede accuracy. Anote horário, consulta, fonte e status. Não misture resultado ao vivo no valor de referência sem validar o dado.

Ambientes separados

1) Fixtures determinísticas para a suite; 2) backend integrado offline; 3) smoke de API externa em baixa frequência; 4) demo ao vivo ou demonstração controlada claramente identificada. Evite depender da Open Library para completar cada execução de CI/teste.

4. Catálogo de testes automatizados por componente

Esta tabela amplia o plano de 24 perguntas com os testes internos que sustentam as funcionalidades. IDs NLP, ENT, DIA, API, RES, UI, E2E, DATA, MET, RUN e REG identificam famílias. A prioridade “MVP” marca comportamento coberto antes da entrega; P1/condicional depende de a melhoria entrar no código.

Normalização

ID	Comportamento coberto	Ação/execução	Assert principal	Prioridade
NLP-01	Texto vazio	Normalizar e interpretar	Retorna estado de entrada vazia; não consulta API.	MVP
NLP-02	Caixa e espaços	Normalizar e comparar	A variação de caixa/espaço não altera indevidamente o rótulo.	MVP
NLP-03	Acentos	Comparar scores	Resultado segue política documentada; original e entidade ficam preservados.	MVP
NLP-04	Pontuação/aspas	Extrair entidade	Título não inclui aspas/pontuação espúria; texto original permanece disponível.	MVP

Representação

ID	Comportamento coberto	Ação/execução	Assert principal	Prioridade
NLP-05	Tfidf ajuste separado	Construir vetorizador	Vocabulário/IDF se ajustam apenas na referência; corpus de teste não é lido no fit.	MVP
NLP-06	Frase fora do vocabulário	Transformar e comparar	Sem erro/crash; score baixo ou abstenção conforme política.	MVP
NLP-07	Intenção prevista	Predizer frase nova conhecida por padrão	Retorna intenção, score e evidência do exemplo vizinho.	MVP
NLP-08	Agregação por classe	Calcular agregado configurado	Classe e agregado correspondem à regra congelada e são reproduzíveis.	MVP

Decisão

ID	Comportamento coberto	Ação/execução	Assert principal	Prioridade
NLP-09	Abaixo do limiar	Aplicar política	Abstenção/esclarecimento; não chamar fonte externa.	MVP
NLP-10	Margem de ambiguidade	Aplicar política	Pergunta de esclarecimento conforme hipóteses; nenhuma consulta arbitrária.	MVP
NLP-11	Aceitação pelo limiar e margem	Aplicar política	Intenção aceita; parâmetros seguem para extração.	MVP
NLP-12	Fora do escopo	Aplicar política/regras explícitas	Abster-se ou encaminhar informativamente; não inventar intenção de negócio.	MVP
NLP-13	Pontuação não é probabilidade	Inspecionar schema, logs e UI técnica	Campo identificado como similaridade/score; nenhum texto afirma probabilidade calibrada.	MVP

Entidades

ID	Comportamento coberto	Ação/execução	Assert principal	Prioridade
ENT-01	Busca por título	Extrair parâmetros	title correto, sem palavras do comando.	MVP
ENT-02	Busca por autor	Extrair parâmetros	author preserva nome composto completo.	MVP
ENT-03	Busca por assunto	Extrair parâmetros	subject correto; “sobre” não perdido antes da extração.	MVP
ENT-04	Título versus autor	Extrair intenção e entidade	Autor+lista vs título+campo autor; não decidir só pelo verbo “escreveu”.	MVP
ENT-05	Parâmetro ausente	Executar diálogo	Pergunta pelo parâmetro; API não chamada antes da resposta.	MVP
ENT-06	Entidades em conflito	Executar extração/política	Pede confirmação; não descarta informação silenciosamente.	MVP

Diálogo

ID	Comportamento coberto	Ação/execução	Assert principal	Prioridade
DIA-01	Pergunta de esclarecimento	Executar novo turno	Pede nome completo/ação; não assume entidade.	MVP
DIA-02	Resposta à pendência	Enviar turno seguinte	Completa intenção pendente e continua uma vez; não reclassifica fragmento como fora do escopo.	MVP
DIA-03	Lista de resultados	Mostrar lista	Lista é numerada e guarda mesma ordem/IDs na sessão.	MVP
DIA-04	Seleção válida	Usuário envia “o segundo”	Seleciona o segundo ID; sem nova busca por literal “segundo”.	MVP
DIA-05	Seleção inválida	Usuário envia “o quarto”	Informa seleção inválida e mantém contexto recuperável.	MVP
DIA-06	Detalhe da seleção	Perguntar “quem escreveu?”	Consulta/autoria do ID selecionado; não primeiro resultado.	MVP
DIA-07	Sem referência ativa	Usuário pergunta “qual o ano dele?”	Pede qual obra; não inventa contexto.	MVP
DIA-08	Cancelamento	Usuário cancela	Limpa pendência e não realiza consulta posterior.	MVP
DIA-09	Nova busca substitui pendência	Usuário inicia busca explícita por assunto	Nova busca prevalece; não mistura parâmetros antigos.	MVP
DIA-10	Isolamento de sessão	Selecionar “o segundo” em cada	IDs/contextos permanecem separados.	MVP
DIA-11	Mudança de assunto	Nova busca sobre astronomia	Busca atual é astronomia; não reutiliza autor Orwell.	MVP
DIA-12	Recomendação limitada	Processar solicitação	Interpreta descoberta por assunto; não afirma personalização.	MVP

5. Catálogo: serviço, respostas e interface

Serviço de livros

ID	Comportamento coberto	Ação/execução	Assert principal	Prioridade
API-01	Consulta de título	Buscar título com parâmetros codificados	Parâmetro segue adapter; retorna IDs e títulos normalizados.	MVP
API-02	Consulta de autor	Buscar obras de autor composto	Campo correto enviado; autores múltiplos preservados.	MVP
API-03	Consulta por assunto	Buscar subject	Consulta coerente; resposta normalizada em lista.	MVP
API-04	Detalhe por identificador	Consultar detalhe	ID pedido coincide com retorno; campos de obra vs edição identificados.	MVP
API-05	JSON mínimo válido	Normalizar	Campos ausentes são opcionais; app não quebra nem inventa.	MVP
API-06	Lista vazia	Consultar serviço	Estado not_found/search_empty distinto de erro HTTP.	MVP
API-07	Múltiplas correspondências	Consultar e renderizar	Mantém candidatos distintos e IDs; sistema pede seleção.	MVP
API-08	ISBN solicitado ausente	Pedir ISBN	Informa que a fonte não fornece o campo; não diz ISBN inexistente.	MVP
API-09	Falha de rede	Consultar serviço	Erro vira estado de indisponibilidade; nenhuma resposta inventada.	MVP
API-10	Timeout	Consultar com timeout configurado	Finaliza dentro do timeout; mensagem adequada; sem retentativa infinita.	MVP
API-11	429 e Retry-After	Executar política de retentativa	Respeita limite/cabeçalho com tentativas limitadas; teste usa relógio falso.	MVP
API-12	Erro 5xx	Consultar	Retentativa limitada se política permitir; resposta final é fallback.	MVP
API-13	JSON inválido/schema inesperado	Normalizar	Erro controlado e log sem conteúdo sensível; usuário recebe indisponibilidade.	MVP
API-14	Limite e concorrência	Enviar várias requisições em sessões	Limitador evita superar política configurada; teste não espera em tempo real.	MVP
API-15	Cache (se incluído P1)	Chamar adapter duas vezes	Segunda chamada reutiliza cache dentro da validade; consulta diferente não colide.	P1 opcional
API-16	Contagem de requisições	Busca com etapa de detalhe	Chamadas previstas e limitadas; sem uma chamada por resultado sem controle.	MVP
API-17	Parâmetro seguro/codificação	Montar requisição	Cliente usa codificação HTTP/params, não concatenação insegura de URL.	MVP
API-18	Sem acesso à rede nos unitários	Executar suite unitária	Cliente fake intercepta todas as chamadas; suite funciona offline.	MVP

Resposta e interface

ID	Comportamento coberto	Ação/execução	Assert principal	Prioridade
RES-01	Template título	Gerar resposta	Mostra só os campos existentes e identificação da fonte.	MVP
RES-02	Template autor	Gerar resposta	Deixa claro que lista foi retornada pela fonte; não afirma completude mundial.	MVP
RES-03	Template assunto	Gerar resposta	Resultado é apresentado como relacionado ao tema, não recomendação individual.	MVP
RES-04	Campo opcional	Gerar card	Oculta ou informa ausência de forma limpa; demais dados aparecem.	MVP
RES-05	Obra/edição e data	Gerar detalhe	Rótulos distinguem primeira publicação de ano da edição.	MVP
RES-06	Proveniência	Renderizar mensagem	Link/crédito corresponde ao item exibido quando disponível.	MVP
UI-01	Enviar mensagem	Enviar pergunta válida	Mensagem aparece uma vez e resposta chega com estado correto.	MVP
UI-02	Entrada vazia	Enviar vazio/só espaços	Validação clara; sem chamada ao backend/API.	MVP
UI-03	Carregamento e erro	Enviar mensagem	Estado de carregamento termina; erro não deixa chat travado.	MVP
UI-04	Renderização de múltiplos resultados	Abrir resultados	Todos IDs/títulos selecionáveis, sem trocar a ordem.	MVP
UI-05	Seleção do usuário	Selecionar cartão e pedir detalhe	UI envia consulta de detalhes com o título selecionado e mantém o mesmo `session_id`, conforme E01.	MVP
UI-06	Falha da fonte na UI	Enviar nova busca	Exibe mensagem de fonte indisponível e mantém uso básico.	MVP
UI-07	Sem resultado na UI	Enviar consulta	Diferencia ausência de resultado de indisponibilidade.	MVP
UI-08	Acessibilidade/usabilidade básica	Navegar teclado, foco e contraste básico	Campo/envio/resultados operáveis; foco visível e rótulos compreensíveis.	MVP
UI-09	Nova conversa	Iniciar nova conversa após obter sessão	UI descarta UUID anterior; a próxima mensagem inicia sessão independente.	MVP
UI-10	Esclarecimento	Enviar pergunta sem parâmetro obrigatório	Pergunta da CAPITU aparece, sem cartão de livro nem chamada desnecessária.	MVP
UI-11	Seleção pendente	Enviar consulta com múltiplos candidatos e escolher um	Lista permanece ordenada; resposta curta ou clique refere-se à lista da sessão ativa.	MVP
UI-12	Estados sem cartão	Receber `no_results` ou `out_of_scope`	Texto correto é mostrado sem cartão inventado; busca vazia e fora de escopo ficam distinguíveis.	MVP
UI-13	Erro HTTP e falha de rede	Simular HTTP 422 e indisponibilidade de conexão	UI mostra recuperação adequada para cada falha, encerra loading e permite nova tentativa.	MVP
UI-14	Reenvio e carregamento	Enviar uma mensagem e tentar reenviar antes da resposta	Envio duplicado é evitado; loading termina após resposta, erro ou timeout controlado.	MVP
UI-15	Modo técnico, se implementado P1	Abrir modo de demonstração	Scores são rotulados como similaridade; ausência do modo não quebra chat regular.	P1 opcional

Sobre limites da Open Library: limite compartilhado requer teste de concorrência usando relógio/transport fake. Não inferir rate limit após enviar carga real. A suíte default não deve exigir chave; conferir que nenhum segredo está embutido. Smoke live fica manual, com poucas chamadas e conforme as regras atuais da fonte.

6. Catálogo: ponta a ponta, dados, métricas e entrega

Sistema, dados e defesa

ID	Comportamento coberto	Ação/execução	Assert principal	Prioridade
E2E-01	Busca por título completa	“Procure Dom Casmurro”	Interpreta título, consulta, normaliza e mostra resposta/fonte.	MVP
E2E-02	Busca por autor completa	“Quais livros Machado de Assis escreveu?”	Lista de obras do autor; sem tratar como biografia.	MVP
E2E-03	Busca por assunto completa	“Mostre ficção científica”	Consulta tema e exibe resultados.	MVP
E2E-04	Detalhes completos	“Quem escreveu Dom Casmurro?”	Encontra obra, apresenta campo existente e origem.	MVP
E2E-05	Dados necessários ausentes	“Busque um livro”	Pergunta título; API não chamada antes de completar.	MVP
E2E-06	Pergunta ambígua	“Machado”	Pede esclarecimento; próxima resposta continua a tarefa.	MVP
E2E-07	Fora do escopo	“Qual a previsão do tempo?”	Abstenção adequada sem chamar Open Library.	MVP
E2E-08	Múltiplos itens e continuação	Busca → “o segundo” → “quem escreveu?”	Detalhe corresponde à seleção da conversa.	MVP
E2E-09	API indisponível integrada	Busca por título	UI recebe fallback e contexto fica consistente.	MVP
E2E-10	Usuário troca de demanda	Nova busca por astronomia	Contexto anterior não contamina nova intenção.	MVP
DATA-01	Grupos de paráfrase	Auditar grupo_variacao	Nenhum grupo aparece em dois splits.	MVP
DATA-02	Duplicata exata	Comparar normalizados e IDs	Duplicata relatada/revisada; identificadores únicos.	MVP
DATA-03	Balanceamento e classe rara	Contar classes por split	Divergência relatada; sem classe de teste omitida silenciosamente.	MVP
MET-01	Métricas com resposta conhecida	Calcular relatório e confusão	Contagens e denominadores coincidem com cálculo manual.	MVP
MET-02	Taxa de fallback	Calcular separadamente	Total e tipos de fallback aparecem, não somente porcentagem agregada.	MVP
RUN-01	Instalação README limpa	Instalar e executar os passos	Servidor, índice, UI e testes básicos sobem sem arquivo secreto.	MVP
RUN-02	Configuração sem credencial privada	Inicializar MVP	Open Library pública funciona conforme política sem key hardcoded.	MVP
REG-01	Regressão dos erros analisados	Reexecutar após correção	Erro corrigido fica coberto e versão/conjunto atualizado.	MVP
DOC-01	Histórico de resultados	Revisar entrega	Todo resultado inclui versão e modo controlado/ao vivo; nenhum caso não rodado marcado passou.	MVP

DEF-01 - Pergunta inédita; DEF-02 - Explicação individual. São verificações de ensaio/autoria, não assertions automatizadas. O professor pode introduzir formulação nova; a equipe demonstra resposta, esclarece ou aponta limite e correção. O objetivo não é prometer que qualquer frase inédita será interpretada corretamente.

7. Suite de aceitação de 24 perguntas - T01 a T12

Exigência oficial: pelo menos 20 casos com esperado, obtido e resultado. Os 24 seguintes dão margem mínima e cobrem reformulação, ambiguidade, ausência, fora de domínio e diálogo. São casos planejados, ainda sem resultado obtido. Definir parâmetros e fontes controladas antes de rodar.

ID e entrada	Intenção esperada	Comportamento esperado
T01 Procure Dom Casmurro	buscar_por_titulo	Com fixture determinística, consulta título e lista candidatos.
T02 Você encontra o livro A Hora da Estrela?	buscar_por_titulo	Extrai título sem comando e apresenta resultados/fonte.
T03 Estou atrás de um livro chamado 1984	buscar_por_titulo	Reformulação; aceita se passar política congelada, senão registra falha/abstenção.
T04 Procure Dom Casmuro	buscar_por_titulo	Pequeno typo; consulta candidata ou pede confirmação, nunca inventa match.
T05 Quais livros Machado de Assis escreveu?	buscar_obras_autor	Consulta por autor e apresenta lista.
T06 Mostre obras de Clarice Lispector	buscar_obras_autor	Preserva autor composto completo.

ID e entrada	Intenção esperada	Comportamento esperado
T07 Quero ler algo escrito por George Orwell	buscar_obras_autor	Reformulação; avaliar reconhecido ou abstenção conforme split, sem alterar depois.
T08 Quero livros sobre inteligência artificial	buscar_por_assunto	Extrai assunto e consulta categoria/subject.
T09 Me mostre ficção científica	buscar_por_assunto	Interpreta gênero e retorna obras controladas.
T10 Alguma leitura a respeito de astronomia?	buscar_por_assunto	Paráfrase de assunto; avaliar interpretação definida.
T11 Quem escreveu Dom Casmurro?	consultar_detalhes	Resolve título, mostra autor se campo disponível e indica fonte.
T12 Quero saber mais sobre A Hora da Estrela	consultar_detalhes	Mostra detalhes do item identificado ou pede seleção.

8. Suite de aceitação - T13 a T24

ID e entrada	Intenção/estado esperado	Comportamento esperado
T13 Livros de história	Assunto ou esclarecimento	Política congelada antes da execução; não escolher esperado após ver saída.
T14 Machado	Esclarecimento	Pede nome completo/confirma hipótese; não assume qual pessoa ou ação.
T15 Busque um livro	buscar_por_titulo, incompleta	Pergunta o título e não chama a API antes do parâmetro.
T16 Mostre livros de um autor	buscar_obras_autor, incompleta	Pergunta quem é o autor.
T17 Qual a previsão do tempo?	Fora do escopo	Abstenção simples; não consulta API de livros.
T18 Renove meu empréstimo	Operação fora do escopo	Explica que CAPITU não opera empréstimos; orienta biblioteca.
T19 Procure Zyx Livro 8472	buscar_por_titulo	Retorno vazio controlado: “não encontrei nesta fonte”; não afirmar inexistência.
T20 Obras de Zyx Autor 8472	buscar_obras_autor	Retorno vazio controlado e pedido de revisão do nome.
T21 Procure 1984	buscar_por_titulo	Timeout injetado: mensagem de indisponibilidade, sem crash.
T22 Procure Dom Casmurro	buscar_por_titulo	Vários resultados controlados; numera e pede seleção.
T23 Busca → “o segundo” → “quem escreveu?”	Seleção + consultar_detalhes	Seleciona ID 2 e responde para a obra escolhida.
T24 Busca por Orwell → nova busca sobre astronomia	buscar_por_assunto	Nova demanda substitui contexto de autor.

Para executar: adicionar Resultado obtido, Passou?, versão, data e modo. Registre score/parâmetros para diagnóstico. T19/T20 usam fake vazio para estabilidade. T21 não causa timeout ao vivo. T13 recebe oráculo aprovado pelo grupo antes da execução. Os 24 casos atendem ao mínimo como plano; só contam como evidência após preenchimento real.

9. Dataset, generalização e prevenção de vazamento

Verificação	Regra e evidência
Origem	Identificar autorais, coleta consentida/simulada e versões; não chamar exemplos sintéticos de pesquisa com público
Guia de rótulos	Definir intenção, entidade e casos difíceis antes da coleta
Grupos de variação	Manter paráfrases próximas, templates e derivados no mesmo grupo de split
Ajuste do vetorizador	fit/fit_transform somente referência/treino; validação/teste usam transform
Seleção de limiar	Usar validação; escolher após congelar teste; registrar configuração
Duplicatas	Auditar ID, texto normalizado e grupos relacionados entre arquivos
Balanceamento	Contar exemplos/classe em cada split e destacar classe pequena
Entidades inéditas	Exercitar nomes de autor/títulos que não são somente os exemplos mais repetidos
Correção pós-teste	Usar falhas do teste para melhoria transforma o conjunto; repetir nova avaliação independente
Artefatos	Guardar hash/versão de corpus, split, biblioteca, configuração e commit associado

Split recomendado pelo plano

Referência/treino 60%, validação 20%, teste 20% por grupo de formulação, estratificado quando o volume permitir. Para aproximadamente 120 frases e quatro classes, alguns grupos terão poucos casos: reportar contagem por intenção; não inferir precisão estatística ampla. Divisão aleatória linha a linha pode vazar paráfrases.

No motor por similaridade, frases de referência funcionam como exemplos rotulados consultados. Ajustar IDF também é etapa de preparação. Não descrever essa implementação como classificador supervisionado treinado se não houver regressão logística/Naive Bayes/etc.

10. Métricas, denominadores e critérios de análise

Medida	Definição para o projeto	O que não esquecer
Taxa de sucesso funcional	Casos cujo comportamento completo foi correto ÷ casos executados	Pode contar fallback correto como sucesso; definir oráculo por caso.
Accuracy de intenção	Intenções corretas ÷ entradas com rótulo único	Ambíguos ficam em avaliação de diálogo, ou têm conjunto de rótulos válido definido.
Precision por intenção	TP/(TP+FP)	Baixa precision indica consultas naquela intenção disparadas indevidamente.
Recall por intenção	TP/(TP+FN)	Baixo recall indica mensagens daquela intenção perdidas/abstidas.
F1 e macro-F1	Média harmônica P/R e média das classes	Macro mostra classe fraca mesmo quando uma classe domina.
Matriz de confusão	Contagens real × previsto, com rejeição explicitada	Não esconder classe “abstenção” nem contar ambiguous como qualquer coisa.
Taxa de fallback	Fallbacks ÷ entradas; ainda separar adequados e inadequados	Taxa baixa pode ocultar falsa aceitação; taxa alta pode mostrar baixa utilidade.
Acerto de entidades	Entidades corretas ÷ entidades avaliadas	Calcular separadamente da intenção.
Taxa de erro externo	Respostas de erro/falha ÷ consultas externas simuladas	Fixtures medem tratamento; não estima uptime real.
Latência, opcional	Tempo por fase e ponta a ponta	Separar API externa de processamento local; descrever amostra.

Matriz do erro por camadas

Para cada falha, localizar uma ou mais etapas: intenção → entidade → estado/contexto → query/HTTP → normalização → resposta/UI. Guardar input, esperado/obtido, scores, estado prévio, fixture/status, causa provável, impacto, ação e teste de regressão.

Exigência: analisar no mínimo três falhas observadas. Não selecionar somente casos simulados de API sem falhas reais do sistema. Se os 24 casos não renderem três erros, ampliar com paráfrases e entradas difíceis, registrar descobertas e não fabricar dados.

11. API externa, fixtures e smoke tests

- Fixture JSON: guardar respostas pequenas reduzidas às chaves necessárias, IDs inventados/claramente controlados e origem declarada.
- Testar consulta do adapter: método, endpoint, query parameters e codificação, em vez de afirmar dependência exata da ordenação viva.
- Testar respostas: lista válida, múltiplos candidatos, vazio, autor múltiplo, campo ausente, obra/edição, JSON inválido e erro HTTP.
- Mock de rede: bloquear chamada real no conjunto padrão; falhar teste explicitamente se uma requisição externa escapar do fixture.

- Rate limiter: usar relógio falso e requisições concorrentes simuladas; teste não aguarda intervalos reais nem gera rajada ao vivo.
- Smoke opcional: uma consulta deliberada por rota/recorte, anotada com hora, query, status e esquema mínimo; manter baixa frequência e consultar política Open Library atual.
- Separar fato: fonte fora do ar é falha externa daquele momento; retorno vazio não prova que a obra inexiste; campos opcionais ausentes não são erro do classificador.
- Proveniência: resultado exibido aponta fonte quando disponível e nunca afirma disponibilidade no acervo universitário.

A Open Library documenta política de consultas e recomenda limitar/cuidar de uso. Antes da execução, Miguel registra política vigente em G04 e Emely codifica limite compartilhado em E10. Não fixar em teste uma expectativa temporal do serviço sem verificar a documentação atual.

12. Interface, estados de diálogo e apresentação

Sequência manual	Passos	Verificação
UI-01	Abrir CAPITU local; enviar mensagem válida	Mensagem e resposta única, ordem legível, sem bloqueio
UI-02	Enviar vazio/só espaços	Aviso; nenhuma busca desnecessária
UI-03	Fazer backend atrasar/falhar	Indicador para e erro pode ser recuperado
UI-04	Mostrar lista controlada com três itens	IDs/títulos e ordem visíveis; seleção possível
UI-05	Clicar em um cartão e pedir detalhe	UI envia pergunta com título selecionado e `session_id` atual
UI-06	API simulada como indisponível	Usuário entende que fonte falhou; estado não fica preso
UI-07	API controlada sem resultado	Mensagem difere de indisponibilidade
UI-08	Navegar por teclado/foco/labels	Controles operáveis e mensagens compreensíveis
UI-09	Iniciar nova conversa	UUID da conversa anterior deixa de ser enviado
UI-10	Receber pedido de esclarecimento	Pergunta aparece sem livros incorretos
UI-11	Exibir seleção pendente e concluir escolha	Ordem e sessão preservadas; detalhe corresponde ao candidato escolhido
UI-12	Receber no_results e out_of_scope	Textos são distintos e nenhum cartão é inventado
UI-13	Receber HTTP 422 e simular falha de rede	Erros são distintos, loading termina e há nova tentativa possível
UI-14	Tentar reenvio enquanto loading	Só uma requisição por ação; sem mensagem duplicada
UI-15	Ativar modo técnico, se implementado	Score é explicitado como similaridade; UI comum continua funcional

Estado da interface: Millena concluiu apenas o design visual; a implementação web é a task M02, a integração com `POST /api/chat` é M03 e a validação dos fluxos/estados é M05/M08. M00 preserva o design como evidência, sem afirmar que existe código pronto. Millena implementa apresentação e consumo HTTP; não implementa nem altera o núcleo de PLN.

Desafio de defesa

Treinar formulação que não esteja no corpus: alguém pede “algo parecido com 1984” ou combina autor e tema. Registrar a pergunta antes, mostrar a decisão real, aceitar esclarecimento/abstenção como comportamento defensável e explicar qual mudança em dados/regra/teste faria. Não adicionar a pergunta ao corpus e reportá-la como inédita na mesma avaliação.

13. Rotina da equipe e critérios de conclusão

Responsável	Pacote de trabalho de testes	Quando/entrega
Emely	NLP/ENT/DIA/API/E2E/MET/REG; mock padrão; métricas; três falhas	Automação e integração até 12/11; diagnóstico até 15/11
Millena	Implementar UI a partir do design (M02), integrar contrato (M03), UI-01 a UI-14, roteiros e screenshots	Protótipo simulado em 27/10; integração e validação até 12/11; revisão até 24/11
Miguel	G03 fixtures, G04 smoke/sondagem, T01-T24, RUN-01, evidências	Tabela consolidada até 12/11; instalação até 16/11
Todos	Revisão cruzada e ensaio inédito; autoria e limites	Ensaio de equipe em 22/11; versão final 24/11

Checklist por task

- [ ] A especificação tem entrada e estado definidos antes da execução?
- [ ] Há resultado esperado verificável, inclusive efeitos colaterais de API/contexto?
- [ ] A execução registra versão, fixture/modo, obtido e passou/falhou/bloqueado?
- [ ] Uma falha leva ao componente provável e vira regressão após correção?
- [ ] Dados, logs e evidências não contêm credenciais ou dados pessoais?

- [ ] O integrante responsável consegue explicar por que a verificação é adequada?

Ordem até a entrega

Até 12/10: contrato/backend mínimo; 20/10: corpus/similaridade inicial; 31/10: entidades/contexto; 06/11: quatro intenções integradas; 12/11: congelamento funcional, executar coleta principal; 17/11: falhas e reprodução; 21/11: relatório/pacote candidatos; 22/11: ensaio; 23-24/11: apenas bloqueadores, regressão, congelamento e backup; 25/11: entrega.

14. O que deve constar na tabela final de resultados

Coluna	Exemplo de conteúdo esperado
ID	T11
Entrada / sequência	“Quem escreveu Dom Casmurro?”
Estado inicial	Sessão limpa; versão v1.0.0; fixture search-dom-casmurro.json
Intenção/entidade esperadas	consultar_detalhes; title=Dom Casmurro; field=author
Comportamento esperado	Resultado com autor, se campo retornado, e origem; não inventar dado
Obtido	Transcrição curta ou referência a log, IDs e mensagem
Passou?	Sim / Não / Bloqueado / Não executado; critério se falhou
Scores e estado	Score/margem, decisão e IDs selecionados quando útil
Modo / versão	pytest mock, backend controlado, UI manual ou smoke live; commit/dataset
Evidência	Caminho de saída, fixture ou screenshot sem segredo

Registros não feitos: antes da execução, Resultado obtido fica vazio ou “Não executado”; nunca preencher como passou com resposta estimada. Após execução, preservar falhas originais; versão corrigida gera outra linha/execução.

Exemplo estrutural sem resultado inventado

ID	Esperado	Obtido	Situação
T21	timeout simulado produz indisponibilidade; sem crash	A preencher na execução	Não executado

A tabela da A3 pode ser uma planilha ou CSV; este documento define os campos e o catálogo. Atualizar os casos diretos para usar os mesmos IDs T01-T24 do planejamento CAPITU para manter rastreabilidade.

15. Critérios de aceite do conjunto de testes

Gate	Condição para marcar concluído
GATE-A Planejamento	T01-T24 têm pré-condições/oráculos congelados e cobrem mínimo oficial.
GATE-B Corpus	Splits/grupos sem vazamento conhecido; fit só no treino; contagens por classe guardadas.
GATE-C Unitários	Lógica de decisão, contexto e adapter testada com casos normais, borda e erro.
GATE-D Integração	Quatro fluxos E2E usando API controlada; consulta é coerente com intenção/parâmetro.
GATE-E Resiliência	Vazio, campo ausente, múltiplos resultados, rede/timeout/429/5xx e JSON inválido têm saída definida.
GATE-F UI	Mensagens, lista/cartões, loading, erros, sessão e acessibilidade básica verificados manualmente na UI implementada a partir do design.
GATE-G Métricas	Resultados reproduzíveis; taxa de sucesso, métricas de classe/confusão e fallback têm denominadores.
GATE-H Falhas	Pelo menos três falhas reais examinadas; causa e melhoria fundamentadas.
GATE-I Entrega	README funciona em ambiente novo; release/pacote e tabela de evidências conferidos.
GATE-J Defesa	Os três integrantes conseguem explicar mecanismo, teste, contribuição e limite.

Um gate que falhe não deve ser ocultado. Registrar o que bloqueia, quem resolve e data; a ausência de teste executado não equivale a aprovado. Resultados e meta interna devem ser reportados mesmo se abaixo de 85%.

16. Referências e relação com documentos existentes

Enunciado oficial

A3_Projeto_Chatbots_IA_40_pontos_20260923193204(2).docx, entregue pela equipe: R1-R7; etapas; relatório; testes; critérios.

Aula complementar

Aula_A3_Tecnologias_Chatbots_IA_Detalhada071020261_20261007160815.pdf, 23 páginas, Professor Marcelo da Silva: intenções/contexto; TF-IDF; treino/teste; fallback; métricas; defesa.

Planejamento do grupo

CAPITU_Planejamento_Detalhado_Equipe.pdf: escopo aprovado, quatro intents, entidades, API, 24 casos-base, limites e métricas.

Plano de tarefas

CAPITU_Plano_Tarefas_Equipe_Entrega_25_11_2026.pdf: E/M/G tasks, dependências, entrega, fixtures, T01-T24 e papéis de validação.

scikit-learn: text features

https://scikit-learn.org/stable/modules/feature_extraction.html#text-feature-extraction

scikit-learn: metrics

https://scikit-learn.org/stable/modules/model_evaluation.html#classification-metrics

scikit-learn: common pitfalls

https://scikit-learn.org/stable/common_pitfalls.html

Open Library APIs / guidelines

https://openlibrary.org/developers/api

Open Library Search API

https://openlibrary.org/dev/docs/api/search

Open Library Books API

https://openlibrary.org/dev/docs/api/books

FastAPI testing

https://fastapi.tiangolo.com/tutorial/testing/

HTTPX timeouts

https://www.python-httpx.org/advanced/timeouts/

pytest fixtures

https://docs.pytest.org/en/stable/how-to/fixtures.html

Proveniência: os planos e cenários estão alinhados ao escopo declarado e à aprovação relatada pelo grupo. O código e os testes ainda devem ser desenvolvidos e executados. Documentação online pode mudar; reconferir durante a implementação. Esta documentação foi redigida com apoio de IA generativa e precisa de revisão pela equipe antes de ser entregue como parte do projeto.